

Tokenization и Embeddings

СОДЕРЖАНИЕ

1. Токенизация	1
Виды токенизации:	1
Character-level.....	1
Word-level.....	2
Subword-level.....	2
Основные методы Subword-level токенизации:	2
Byte Pair Encoding (BPE).....	2
WordPiece	3
SentencePiece (Unigram LM)	3
2 Векторизация	3
One-Hot Encoding.....	3
Word2Vec.....	3
Современные методы	4

Модели не работают с текстом напрямую, они получают на вход последовательность векторов. Преобразование текста в такую последовательность происходит в два этапа:

- Токенизация — это процесс разбиения текста на более мелкие единицы (токены)
- Векторизация – преобразование каждого отдельного токена в вектор.

1. ТОКЕНИЗАЦИЯ

Виды токенизации:

Character-level

Токенизация производится по отдельным символам.

Преимущества:

- маленький словарь
- нет OOV

Недостатки:

- Длинные последовательности векторов
- Сложнее выявлять семантическую связь между токенами

OOV (Out-of-Vocabulary) — это слова, которые встретились во время инференса/теста, но отсутствовали в словаре, построенном на тренировочных данных.

Word-level

Токенизация производится по целым словам.

Преимущества:

- Интуитивно понятно

Недостатки:

- Большой словарь
- OOV

Subword-level

Компромисс между Word-level и Character-level. Токенизация производится по фрагментам слов.

Преимущества:

- Баланс размера словаря и информативности
- Можно избежать OOV

Недостатки:

- Сложнее в реализации

Пример.

Фраза: Tokenization is fascinating!

Уровень	Токены	Кол-во токенов
Character	["T", "o", "k", "e", "n", "i", "z", "a", "t", "i", "o", "n", "..."]	28
Word	["Tokenization", "is", "fascinating", "!"]	4
Subword	["Token", "ization", "is", "fasc", "inating", "!"]	6

Основные методы Subword-level токенизации:

Byte Pair Encoding (BPE)

Используется в серии GPT (OpenAI).

Алгоритм:

1. Анализируется весь обучающий корпус текстов. Изначально алфавит состоит из всех байт.
2. Алгоритм считает, какая пара токенов встречается вместе чаще всего, добавляет её в словарь и заменяет в корпусе.
3. Повторяем шаг 2, пока словарь не достигнет заданного размера

WordPiece

Используется в семействе BERT (Google).

Принцип работы (аналогичен BPE, но с другой метрикой):

- Вместо подсчета частоты пары, алгоритм вычисляет, какое объединение максимально увеличит вероятность языковой модели на обучающем корпусе.
- Формула оценки: $\text{score} = P(AB) / (P(A) * P(B))$. Если A и B часто идут вместе, их объединение будет сильно повышать score.

SentencePiece (Unigram LM)

Используется в T5, LLaMA (Meta).

Алгоритм:

1. Инициализируем огромный словарь (например, берём наиболее частые подстроки или применяем BPE с большим размером словаря)
2. Выбираем токены, исключение которых приведёт к наименьшим потерям (10 – 20% от размера словаря). Исключаем их из словаря.
3. Повторяем шаг 2, пока словарь не достигнет заданного размера

2 ВЕКТОРИЗАЦИЯ

One-Hot Encoding

Каждый токен представляется в виде One-Hot вектора, размер которого равен размеру словаря.

Например, словарь: [дом, машина, человек]

Вектора для токенов: Дом – [1, 0, 0], Машина – [0, 1, 0], Человек – [0, 0, 1]

Единственный плюс – простота реализации.

Недостатки:

- большая размерность вектора,
- отсутствие семантической связи между векторами

Может использоваться в качестве подготовительного этапа для других методов векторизации, когда каждому токenu из словаря нужно сопоставить One-Hot вектор для дальнейших расчётов.

Word2Vec

Предложен в 2013 году. Имеет несколько вариантов архитектур. В качестве примера рассмотрим «skip-gram с отрицательной выборкой».

Обучение:

1. Составление обучающей выборки (берутся пары слов, стоящих рядом друг с другом)

Мой дядя **самых** честных правил когда не в шутку ...

Самых мой
Самых дядя
Самых честных
Самых правил

Мой дядя самых **честных** правил когда не в шутку ...

Честных дядя
Честных самых
Честных правил
Честных когда

Мой дядя самых честных **правил** когда не в шутку ...

Правил самых
Правил честных
Правил когда
Правил не

2. Инициализируются две матрицы (embeddings (для первого слова в паре) и context (для второго)) размером (размер словаря * длина вектора).
3. Модель обучается предсказывать, находятся ли два слова в одном контексте (при этом используются положительные примеры из обучающей выборки и отрицательные – слово из пары и случайно выбранное слово). Проходимся несколько раз по всей выборке, на каждый положительный пример берём несколько отрицательных.
4. Получаем вектора токенов из матрицы embeddings

В итоге обучения вектора слов семантически связаны. Например, можно получить следующие выражения: «Король – мужчина + женщина = королева».

Современные методы

В качестве современных методов используются модели, построенные на архитектуре трансформеров. Их преимуществом является понимание контекста (например, многозначные слова получают разные вектора в зависимости от контекста, в котором они встречаются).

В качестве примера можно привести BERT.